神经网络与深度学习 · 课程项目

基于 CLIP 的图文跨模态检索

冻结视觉分支，比较文本投影微调与手写 LoRA 的检索收益和运行代价。

项目报告 | 中文说明版 | 2026-11-02

作者：待定 院系与学校：待定

最终测试 mR	C□B 配对增益	C 组可训练比例
89.21%	+1.39 个百分点	0.3029%

摘要

本项目使用真实 Flickr30k 图片与人工描述，在固定图像级划分上比较原始 CLIP、仅训练文本投影层、文本 Q/V 手写 LoRA 联合投影层三种配置。视觉分支全程冻结；同种子的训练组共享原始权重、抽样计划与超参数。最终测试覆盖完整的 1,000 张图片和 5,000 条 caption。结果显示，投影层训练已贡献较大收益，加入 LoRA 后三个配对种子均进一步提升；但当前未合并实现增加了文本编码延迟。报告结合训练曲线、全库指标、复杂度、同步计时和真实失败，给出所测配置下的结论与边界。

关键词：CLIP；图文检索；LoRA；参数高效微调；Flickr30k。

本中文报告辅助说明项目。正式课程论文另以英文 IEEE Conference LaTeX/PDF 提交。所有定量数据均读取既有实验记录，本轮未新增训练或测试推理。

01 项目问题与课程要求

要回答的两个问题

第一，冻结视觉分支后，文本侧微调能否改善零样本检索？第二，在仅训练投影层这一更强基线上，额外训练注意力 Q/V 的 LoRA 是否仍有收益，代价是什么？

CLIP 的图文共享表征来自既有工作 [1]，LoRA 的低秩更新来自既有方法 [2]。本项目的工作是手写实现、受控实验、正确评估和复现材料组织，不将这些基础方法表述为原创算法。

老师要求	本项目对应实现
至少训练或微调一个网络模块	B 更新 text_projection；C 更新文本 Q/V LoRA + text_projection
公开数据、来源及划分	Flickr30k；实际 JSON 31,014 张；29,000/1,014/1,000 固定 split
同图所有 caption 留在同一划分	同时检查 image_id 与 filename，无跨集合交集
至少两组有意义的公平对比	A－C：总体微调收益；B－C：注意力适配的额外收益
任务指标与复杂度	双向 R@1/5/10、MedianRank；Params、MACs/FLOPs、耗时
代码与真实可视化	手写层、训练/恢复入口；loss、检索 Top-5、成功和失败
英文 IEEE 论文	保留官方 IEEEtran 版式；个人信息待填写
2－5 分钟视频或现场演示	已制作带讲稿的答辩 PPT；视频/现场演示另行完成

采用老师原文中较严格的“两组有意义对比”要求。B 不是装饰性实验，它决定能否将增益正确归因到新增注意力适配，而不是把全部提升都算作 LoRA 的作用。

02 数据来源与防泄漏协议

图片目录包含 31,783 张 JPEG；挂载的 Karpathy 格式标注仅引用 31,014 张，每图 5 条人工描述，共 155,070 条。全部被引用图片成功匹配并可完整解码，另外 769 张不进入实验。数据规模按实际输入文件报告，不改写成其他论文常见的划分计数。

划分	图片数	可用 caption 数
Train	29,000	145,000
Validation	1,014	5,070
Test	1,000	5,000
合计	31,014	155,070

划分与质量控制

直接读取 JSON 的 split 字段，未自行随机重划分。图像 ID 与文件名均唯一，三个集合交集为零；同一张图片的五条描述全部保留在同一集合。图像定位使用 filename，不把内部 imgid 拼成图片文件名。

完整解码检查覆盖 31,014 张被引用图像，损坏或无法解码为 0；检查了非空 caption、重复标识与跨 split 交集。上述检查保证标注身份隔离，不代表已排除视觉近重复，更不能证明与 CLIP 原始预训练数据没有重叠。

预处理与使用范围

图片转为 RGB，采用原始 CLIP 的 PIL 预处理，输出 224×224。文本使用配套 tokenizer，最多 77 tokens。训练和测速固定填充 77；评估按批次最长文本填充，但不超过相同上限。

Flickr30k 原始门户 [12] 将图片提供给非商业研究和教育使用，并声明不拥有图片版权，需遵守原始图片与平台条件。不能将“公开可获取”解释为任意用途或任意再分发许可。

标注 SHA256：db779ee2c5df40c25ff0eebeca464f6124b620cc4a9398650aea71fd1b53d4af

03 网络、手写 LoRA 与损失

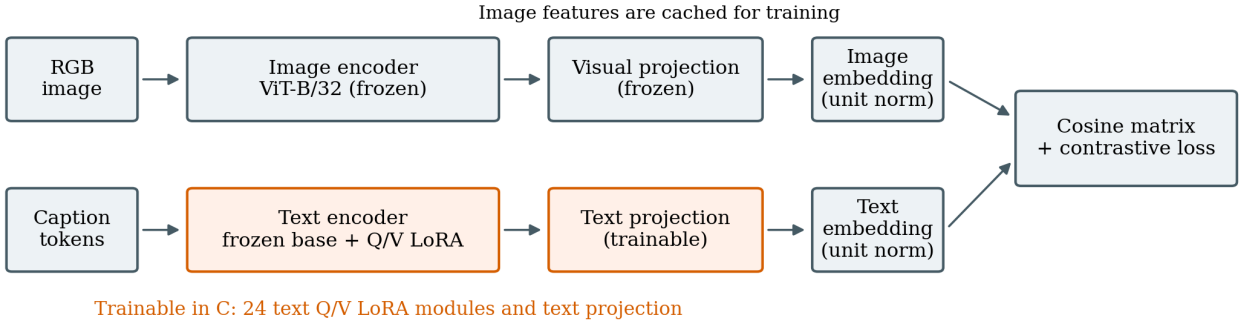


图 1 C 组计算路径。视觉编码器与投影冻结，文本 Q/V 低秩分支和文本投影可训练。

CLIP 先分别编码图片和句子，再通过投影进入 512 维公共空间；L2 归一化后，以点积计算余弦相似度。投影层改变最终对齐，而 Q/V 更新可以改变文本注意力中的匹配与信息聚合。

组别	可训练部分	用途
A	无，原始 CLIP	零样本基线
B	text_projection	投影层适配对照
C	文本 12 层 Q/V 的手写 LoRA + text_projection	主实验；共 24 个 LoRA 模块

手写层计算 $y = Wx + b + (\alpha/r)BAx$。设 r=8、α=8，A 以 Kaiming uniform 初始化，B 为零，无 LoRA dropout。初始化时新增分支为零；两次真实更新检查中 LoRA 与投影更新，冻结参数未变化。

文本宽度 512，LoRA 参数为 $24\times8\times(512+512)=196,608$；加上 262,144 个投影参数，共 458,752。原始文本权重、视觉编码器、视觉投影和 logit_scale 保持冻结。

每个 epoch 每张训练图像只选择一句 caption，保证一个 batch 内 image_id 不重复。该方案避免重复图片的其他 caption 被对角标签当成负例，但不同图片之间仍可能存在语义相似的负例。

训练使用图到文与文到图交叉熵的平均值。Logits 为冻结温度尺度 exp(logit_scale) 乘余弦相似度；图片特征确定性预计算为 FP32，文本分支在训练中实时前向与反传。

04 受控训练与验证选模

配置	实际记录
硬件	单张 Tesla T4；约 14.56 GiB；cuda:0
模型	openai/clip-vit-base-patch32，权重与 processor 本地离线加载
训练预算	5 epochs；batch64；每轮 454 次更新，末批 8 张
优化器	AdamW；lr=1e-5；weight_decay=0.01
稳定性	梯度范数裁剪 1.0；无学习率调度；初始 GradScaler=1024
精度	文本前向 FP16 autocast；归一化、logits、loss FP32；评估 FP32
重复实验	B/C 各用 seed42/43/44，同种子共享数据与抽样计划
选模	每轮完整验证 mR 选最佳；六次实验均选 epoch5
更新状态	30 轮均未跳过优化器更新

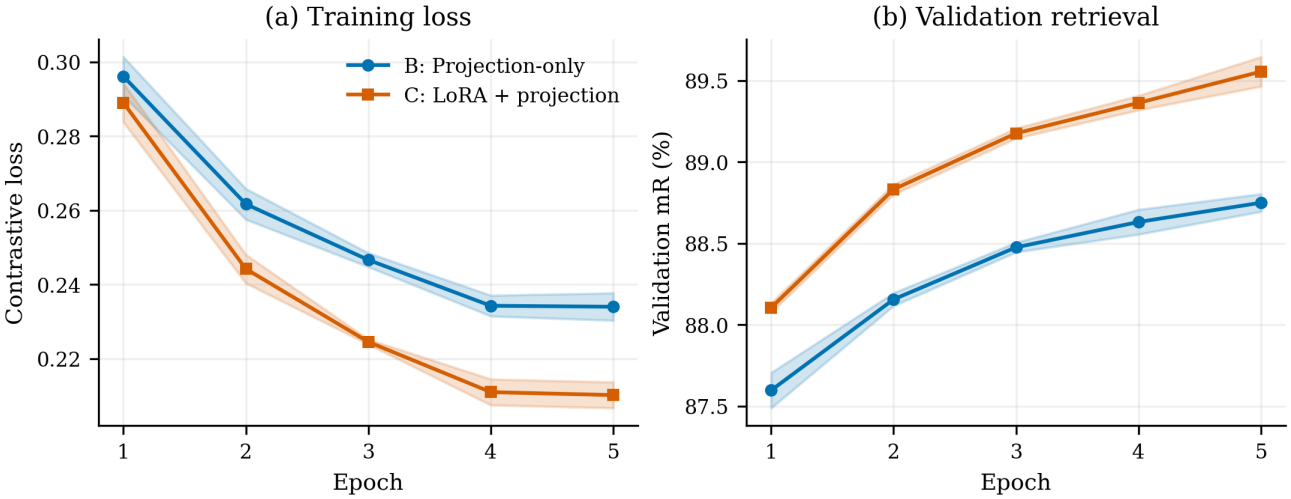


图 2 三个训练种子的均值与样本标准差。未平滑；左右纵轴不同。

验证集 mR：A 为 84.50%，B 为 88.75±0.05%，C 为 89.56±0.09%。这些数用于选择检查点，不能替代最终测试表现。最优轮次均落在预算末轮，因此不能宣称已经充分收敛。

训练环境记录：Python 3.13.15；torch 2.11.0+cu128；torchvision 0.26.0+cu128；transformers 5.16.1；huggingface_hub 1.29.0；Pillow 13.0.0。

05 全候选库评估与主结果

测试候选库固定为 1,000 张去重图片与 5,000 条 caption。先分批提取全部特征，再在完整 1,000×5,000 相似度矩阵上排序。特征提取分 batch，不意味着指标在 batch 内计算。

I2T 以五条正确 caption 中的最佳排名为真值 rank；T2I 以 caption 对应的唯一图片排名为 rank。排名从 1 开始；相同分数按候选索引稳定排序。MedianRank 为普通中位数，偶数查询数取中间两项的平均。mR 为六项 Recall 的算术平均。

图像 → 文本

模型	R@1 (%)	R@5 (%)	R@10 (%)	MedianRank
A 原始 CLIP	79.30	95.00	98.10	1
B 仅投影	81.10 ± 0.52	96.53 ± 0.15	99.03 ± 0.21	1
C LoRA + 投影	84.17 ± 0.46	97.53 ± 0.15	99.40 ± 0.10	1

文本 → 图像

模型	R@1 (%)	R@5 (%)	R@10 (%)	MedianRank
A 原始 CLIP	58.84	83.44	90.08	1
B 仅投影	66.91 ± 0.13	89.29 ± 0.14	94.04 ± 0.03	1
C LoRA + 投影	68.87 ± 0.27	90.40 ± 0.02	94.87 ± 0.10	1

模型	mR (%)
A	84.13
B	87.82 ± 0.14
C	89.21 ± 0.11

B/C 显示三个训练种子的均值 ± 样本标准差（ddof=1），不是置信区间。A 只做一次确定配置的零样本评估。全部 MedianRank 为 1，是因为超过半数查询的真值位于首位，不表示其余查询都成功。

06 两组对比与结果解释

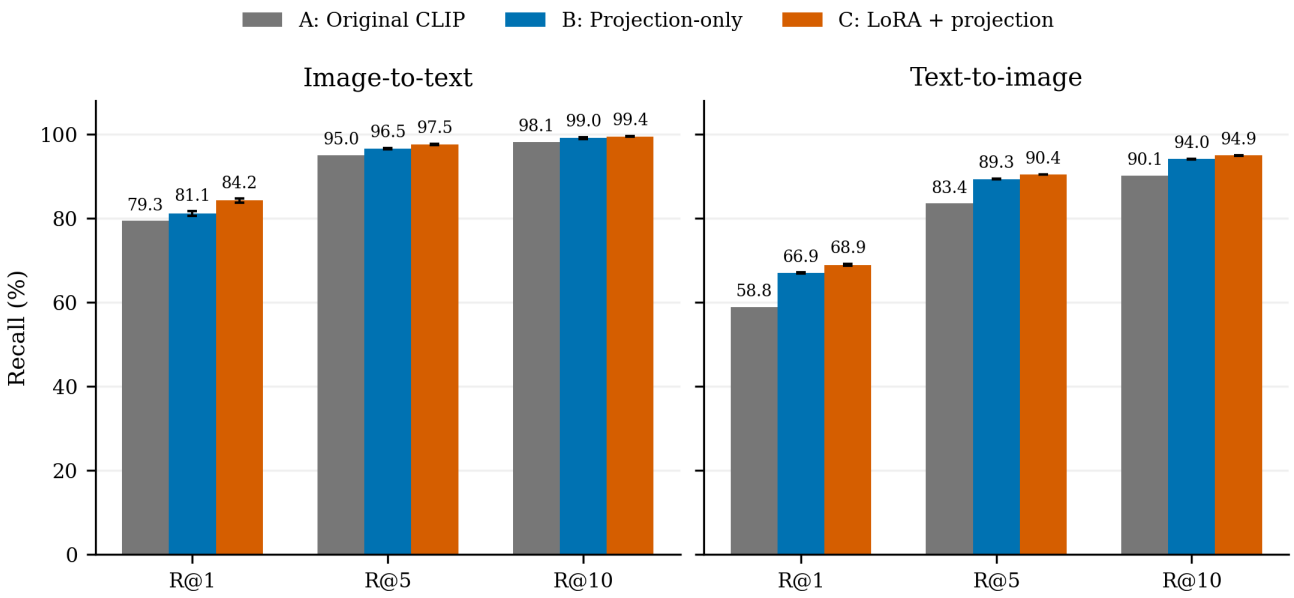


图 3 双向 Recall 对比。误差条来自三个训练种子，不能解释为独立测试样本的置信区间。

A－C：总体适配收益

C 的平均测试 mR 为 89.21%，相对原始 CLIP 提升 5.08 个百分点。该比较支持本项目配置下的微调有效性。B 单独已提升约 3.69 个百分点，说明不能将全部收益归因于 LoRA。

B－C：注意力适配的额外收益

种子	B mR (%)	C mR (%)	C□B（百分点）
42	87.72	89.19	+1.47
43	87.98	89.32	+1.34
44	87.76	89.10	+1.35

三个配对差均为正，均值为 +1.3878±0.0741 个百分点。C 相对 B 的 I2T R@1 增加约 3.07 个百分点，T2I R@1 增加约 1.95 个百分点。已经接近饱和的 I2T R@10 增益较小。

这些结果支持固定数据、预算和超参条件下的额外收益，不证明 LoRA 优于完整文本微调、其他 PEFT 方法或经过独立超参优化的投影基线。三种子一致也不等于统计显著性检验通过。

07 模型复杂度与训练成本

组别	总参数	可训练参数	可训练比例
A	151,277,313	0	0.0000%
B	151,277,313	262,144	0.1733%
C	151,473,921	458,752	0.3029%

组别	图像 GMACs	文本77 GMACs	图文对 GFLOPs
A	4.4088	2.9798	14.7772
B	4.4088	2.9798	14.7772
C	4.4088	2.9949	14.8074

计数输入为一张 224×224 RGB 图像和一条 77-token 文本，约定 1 MAC=2 FLOPs。卷积、线性、注意力两次矩阵乘法及手写 LoRA 的两次投影计入；注意力按全长稠密矩阵计数，包括掩码位置。

不计 bias/残差加法、归一化、激活、Softmax、embedding lookup、LoRA 缩放，以及候选库评分和排序。因此这些值是主要算子的理论计数，不能冒充完整硬件指令或真实耗时。

训练组	平均每轮训练 (s)	峰值 allocated (GiB)
B	20.25	0.696
C	48.91	1.791

训练时间对每组 15 个 epoch 求平均；显存是最大 PyTorch allocated 峰值，不是 reserved，更不是整机全部显存。上述 epoch 时间不包含首次缓存构建与验证。视觉特征缓存加速了训练，不代表端到端从图片读取到结果展示的总时长。

C 每条 77-token 文本新增 15,138,816 MACs，约为基础文本编码的 0.51%。图文对理论计算量约增加 0.20%，但训练仍需穿过中间文本激活进行反传，可训练参数比例不能单独预测训练显存与速度。

08 真实测速与口径

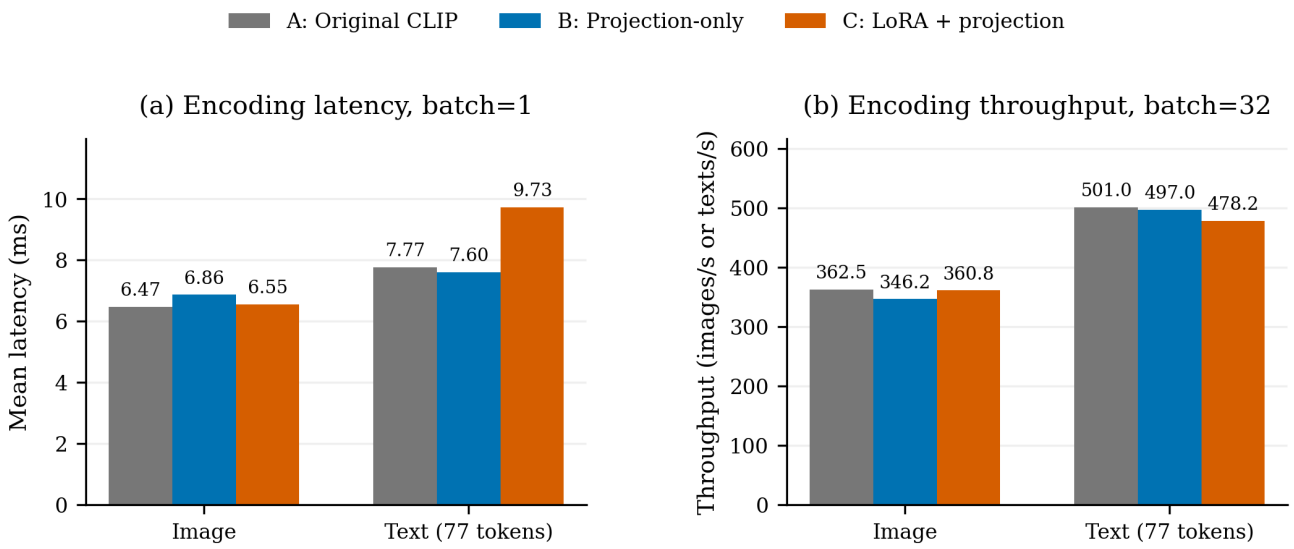


图 4 单 T4、FP32、seed42、LoRA 未合并。批量吞吐与单条延迟是两种测量。

组别	图片均值 ms	图片 p95 ms	文本均值 ms	文本 p95 ms
A	6.472	7.394	7.765	8.971
B	6.864	9.806	7.596	8.599
C	6.546	7.597	9.727	11.167

组别	B32 images/s	B32 texts/s	缓存 T2I ms	缓存 I2T ms
A	362.46	500.98	0.0668	0.1058
B	346.22	497.04	0.0695	0.1103
C	360.80	478.20	0.0736	0.1064

编码延迟预热 20 次、同步墙钟采样 100 次；batch32 吞吐预热 10 次、5 轮×10 次前向。缓存匹配预热 20 次、采样 200 次，轮换 64 个预编码查询。p95 来自同次重复调用，不是跨会话或跨种子的误差估计。

输入与候选特征驻留 GPU。不含文件读取、预处理、tokenization、CPU/GPU 传输、候选库构建和结果展示。缓存 Top-5 时间更不能当作完整请求延迟。C 文本单条编码比 A 慢约 25.3%，说明当前未合并实现的运行成本应单独衡量。

09 T2I 成功与失败案例

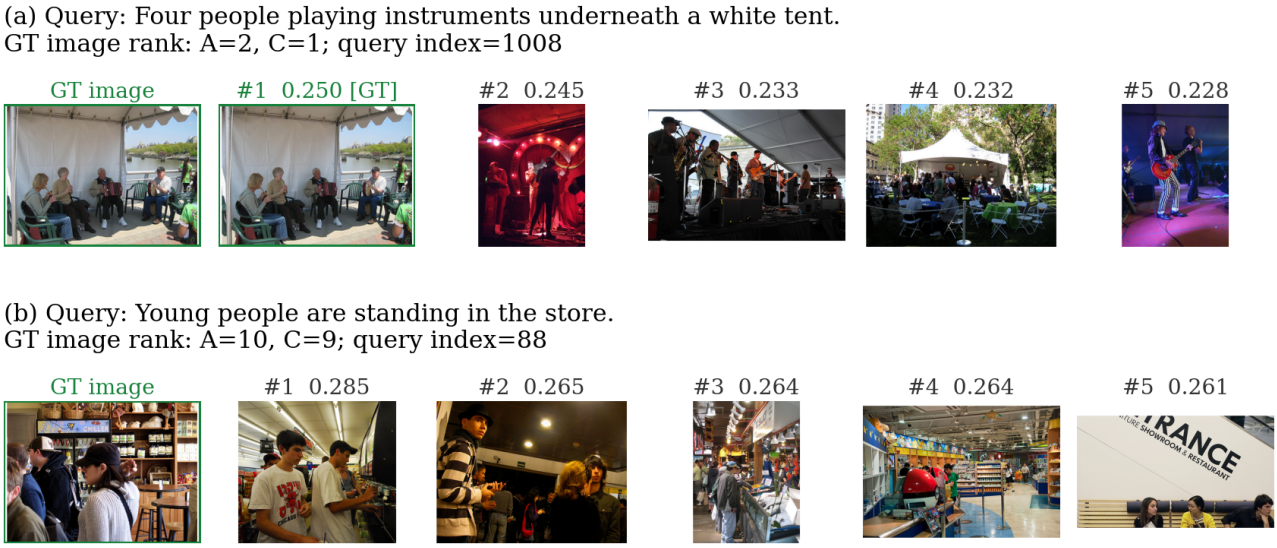


图 5 来自已保存真实检索结果。绿色 GT 是数据对应，不代表其他候选在语义上都不相关。

改善示例：白色帐篷下演奏乐器

查询为 “Four people playing instruments underneath a white tent.”。原始 CLIP 的正确图片为第 2 名，C 组为第 1 名。这是相近候选之间的局部排序改善，不能仅由截图推断模型已经掌握所有关系或数量。

失败示例：商店中的年轻人

查询为 “Young people are standing in the store.”，对应图片 110671448.jpg。A 的真值排名为 10，C 为 9，仍不在 Top-5。返回结果中也有商店或室内人物；该句缺少其他人工标注中的帽子、排队、咖啡店等细节，难以唯一定位实例。

失败体现的是短文本、候选库相似场景与实例级标签之间的歧义，不足以证明某一视觉对象完全未识别。图中分数为各模型的余弦相似度，跨模型分数绝对值变化不能直接代替排名比较。

10 I2T 失败与逐查询审计

(a) Image-to-text: best GT rank A=2, C=1; query index=357



One GT caption: People stand in a warehouse.

1. [GT] 0.280: A group of people are standing in a warehouse.
2. 0.271: Several people are standing and staring up at a work of art.
3. [GT] 0.266: People stand in a warehouse.
4. 0.261: People are admiring a work of art.
5. 0.260: A many in an orange t-shirt, tan shorts and tan and black baseball cap is moving a tall metal cart with sheets of pretzels that is surrounded by similar carts.

(b) Image-to-text: best GT rank A=9, C=6; query index=446



One GT caption: Children are playing tug-of-war.

1. 0.280: Several children are outdoors getting ready to play tug-of-war.
2. 0.268: A woman is standing and talking to a group of children.
3. 0.266: A group of children are playing Tug-of-War.
4. 0.266: The girl in the light pink shirt is playing a game with the other children.
5. 0.266: Elementary school students play tug-of-war.

图 6 C 组真实 Top-5 文本。仓库图改善至 Top-1；拔河图的首个正确 caption 仍排第 6。

仓库图片的首个对应 caption 从第 2 名提高到第 1 名。拔河图片 3483071906.jpg 的五条人工描述包括“Children are playing tug-of-war.”，但模型优先返回属于其他图片的相似描述，真值由 A 的第 9 名改善为 C 的第 6 名。

“活动语义正确”与“属于该图片的五条标注”不是同一个条件。该例提示对应标签不穷尽所有语义相关候选，但不能在看到失败后修改基准标签来提高分数。

方向	两者正确	仅 A 正确	仅 C 正确	两者失败
I2T	750	43	89	118
T2I	2785	157	673	1385

表中覆盖 seed42 的全部查询。C 修复的 Top-1 失败多于退化的成功，但并非所有查询均改善。T2I caption 共享图片，不能把 5,000 条 caption 当成互相独立的统计样本。

11 复现交付与结论边界

现有材料定位

材料	作用
01_experiment_record.ipynb	保留关键历史训练、指标与可视化输出
02_train_from_scratch.ipynb	完整重新训练入口；原始输入另行挂载
03_restore_saved_results.ipynb	恢复检查点并读取/核验已有结果
CLIP_Flickr30k_experiment_artifacts.zip	保存六份检查点、缓存、抽样计划、日志与结果
CODE_AND_ARTIFACT_AVAILABILITY.md	列明精确入口、文件 SHA256 与输入映射

完整恢复曾在后续 Kaggle 会话执行：76 个文件 SHA256 一致，六份检查点加载与文本前向通过，C_seed42 验证指标与原结果最大差为 0。之后的展示读取保存的测试/测速记录，没有把历史日志伪装成新一轮训练。

本轮 Nature Skills 优化只重算保存数据与检查文件/排版，未重新运行训练或测试推理。保存结果的相互一致不等于新环境从零完整复现，二者在交付说明中分别标记。

结论与有针对性的后续实验

在本次固定数据与五轮预算下，投影层训练改善原始 CLIP；增加文本 Q/V LoRA 提供额外增益。与此同时，较小的可训练参数比例没有消除未合并实现的文本编码代价。

当前边界	它限制的结论	能区分问题的后续测试
仅 r=8、五轮预算	不能推断最优秩或充分收敛	匹配 r=4/8/16 与更长验证选模预算
单数据集、1k 图片测试库	不能直接推广到其他域或大索引	其他数据集与更大候选库
未合并 LoRA、GPU 驻留计时	不能代表部署端到端延迟	合并/未合并与完整请求同步测量
单图随机一句训练	同轮未覆盖全部 caption	多正例对比损失与相同训练预算
无视觉近重复/预训练去重证明	身份隔离不等于所有语义独立	近重复审计与明确的预训练污染边界

r=4/16 尚未运行，不在报告中填造消融结果。姓名、院校和邮箱待确定。PPT 与 2–5 分钟演示仍按确认后的展示方案继续完善。

12 参考文献与材料索引

[1] Radford et al. Learning Transferable Visual Models From Natural Language Supervision. ICML, PMLR 139:8748–8763, 2021.
https://proceedings.mlr.press/v139/radford21a.html

[2] Hu et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.
https://arxiv.org/abs/2106.09685

[3] Young, Lai, Hodosh, and Hockenmaier. From image descriptions to visual denotations. TACL 2:67–78, 2014.
https://aclanthology.org/Q14-1006/

[4] Karpathy and Fei-Fei. Deep Visual-Semantic Alignments for Generating Image Descriptions. CVPR, 2015.
https://arxiv.org/abs/1412.2306

[5] Dosovitskiy et al. An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR, 2021.
https://arxiv.org/abs/2010.11929

[6] Houlsby et al. Parameter-Efficient Transfer Learning for NLP. ICML, PMLR 97:2790–2799, 2019.
https://proceedings.mlr.press/v97/houlsby19a.html

[7] Faghri et al. VSE++: Improving Visual-Semantic Embeddings with Hard Negatives. BMVC, 2018.
https://arxiv.org/abs/1707.05612

[8] Loshchilov and Hutter. Decoupled Weight Decay Regularization. ICLR, 2019.
https://arxiv.org/abs/1711.05101

[9] Paszke et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. NeurIPS 32, 2019.
https://arxiv.org/abs/1912.01703

[10] Wolf et al. Transformers: State-of-the-Art Natural Language Processing. EMNLP Demonstrations, pp. 38–45, 2020.
https://aclanthology.org/2020.emnlp-demos.6/

[11] shtvkumar. Karpathy splits for Image Captioning. Kaggle dataset mirror.
https://www.kaggle.com/datasets/shtvkumar/karpathy-splits

[12] University of Illinois. Flickr30k source dataset download and usage information.
https://hockenmaier.cs.illinois.edu/DenotationGraph/data/

完整作者与字段记录见英文项目的 references.bib 及本次文献核验说明。Kaggle 镜像正文无法被当前检索器完整读取，其实际文件身份由项目标注 SHA256 与本地统计界定。